


2WikiMultiHopQA 证据检索事实记录

1. 数据规模

数据切分	问题数	平均候选记忆数	平均图边数	孤立记忆节点数
Train	167,454	31.95	180.72	21,858
Dev	500	31.76	186.22	59
Test	12,076	32.92	192.93	1,907

训练侧包含 3,237,914 个图检索训练 pair，其中正例 404,884 个。Dense-FT 训练侧包含 2,428,267 个训练 pair。

2. 主检索指标



方法	Recall@2	Recall@5	Recall@10	Full Support@5	Full Support@10	MRR
BM25	0.3306	0.5233	0.6774	0.1846	0.3624	0.6593

方法	Recall@2	Recall@5	Recall@10	Full Support@5	Full Support@10	MRR
BM25 + Graph	0.3178	0.5498	0.7345	0.2271	0.4722	0.6237
Dense	0.5383	0.6776	0.7953	0.3628	0.5586	0.8633
Dense + Graph	0.5124	0.6807	0.8153	0.3761	0.6046	0.8706
Dense-FT	0.7019	0.9190	0.9814	0.8143	0.9615	0.9444
Trainable Graph Retriever	0.7359	0.9410	0.9771	0.8876	0.9559	0.9572

Trainable Graph Retriever 的 Recall@2 比 Dense-FT 高 4.8%，Recall@5 比 Dense-FT 高 2.4%，Full Support@5 比 Dense-FT 高 9.0%，MRR 比 Dense-FT 高 1.4%。


Dense-FT 的 Recall@10 比 Trainable Graph Retriever 高 0.4%，Full Support@10 比 Trainable Graph Retriever 高 0.6%。

Dense-FT 的 Full Support@10 比 Dense 高 72.1%。Dense + Graph 的 Full Support@10 比 Dense 高 8.2%。BM25 + Graph 的 Full Support@10 比 BM25 高 30.3%。

从结果形态看，2WikiMultiHopQA 的候选规模和支持句数量会让 top10 指标相对宽松。Test 平均候选记忆数约为 32.92，训练集中平均正例约为 2.42 个/题；在这种设置下，经过监督训练的 Dense-FT 能够把模板化实体关系问题中的支持句排进 top10，并不意外。这个结果更多反映文本排序模型的适配效果，而不是图路径能力。

Trainable Graph Retriever 的优势更集中在靠前位置和结构恢复上，例如 Full Support@5、Path Recall@10、Edge Recall@10。相对而言，top10 上的小幅差异不宜单独放大。BM25 + Graph 和 Dense + Graph 的调参产物实际选择了 max_hops=1，但在平均边数接近 192.93 的较密图上，扩大 hop 也可能引入额外噪声；这一点更适合作为后续对照实验观察，而不是当前结果的直接归因。

3. 结构指标




方法	Connected Evidence Recall@5	Connected Evidence Recall@10	Query-Evidence Connectivity@10	Path Recall@10	Edge Recall@10
BM25	0.0788	0.2171	0.3605	N/A	N/A
BM25 + Graph	0.1264	0.3303	0.4717	0.3841	0.3820
Dense	0.2010	0.3968	0.5535	N/A	N/A
Dense + Graph	0.2341	0.4487	0.6013	0.5813	0.5722
Dense-FT	0.5554	0.7246	0.9432	N/A	N/A
Trainable Graph Retriever	0.5847	0.6977	0.9374	0.9015	0.8626

Trainable Graph Retriever 的 Path Recall@10 比 Dense + Graph 高 55.1%，Edge Recall@10 比 Dense + Graph 高 50.7%。

Dense-FT 的 Connected Evidence Recall@10 比 Trainable Graph Retriever 高 3.9% ， Query-Evidence Connectivity@10 比 Trainable Graph Retriever 高 0.6% 。 Trainable Graph Retriever 的 Connected Evidence Recall@5 为 0.5847 ， Dense-FT 为 0.5554 。

BM25、Dense、Dense-FT 的 Path Recall@10 和 Edge Recall@10 记录为 N/A 。 BM25 + Graph、Dense + Graph、Trainable Graph Retriever 有对应的路径与边恢复指标。

4. 效率指标



方法	端到端耗时 / Query	平均候选记忆数	平均返回边数
BM25	1.85 ms	31.92	0.00
BM25 + Graph	4.57 ms	31.92	36.08
Dense	26.08 ms	31.92	0.00
Dense + Graph	28.00 ms	31.92	39.90
Dense-FT	25.83 ms	31.92	0.00
Trainable Graph Retriever	66.92 ms	31.92	29.33

Trainable Graph Retriever 的耗时比 Dense-FT 高 159.1% ， 比 Dense 高 156.6% 。 Dense + Graph 比 Dense 高 7.4% 。

Trainable Graph Retriever 的平均返回边数为 29.33 。 Dense + Graph 的平均返回边数为 39.90 ， BM25 + Graph 的平均返回边数为 36.08 。