


2WikiMultiHopQA 结构化图检索阶段性结果


本报告记录同一 2WikiMultiHopQA 评测设置下的阶段性结果。测试集包含 12,076 个问题，每题平均候选证据约 31.92 条，所有方法均按 top10 输出进行比较。

本轮新增结果主要关注证据关系的组织方式。表中的 Structure-Aware R-GCN Retriever 指在原有 R-GCN 图检索框架上，调整证据图构建过程后的版本；核心模型仍为 R-GCN，差异主要体现在进入图模型前的结构关系组织。

1. 主检索指标



Full Support@10



Same metric compared across methods


方法	Recall@2	Recall@5	Recall@10	Full Support@5	Full Support@10	MRR
BM25	0.3306	0.5233	0.6774	0.1846	0.3624	0.6593
Dense	0.5383	0.6776	0.7953	0.3628	0.5586	0.8633
Dense-FT	0.7019	0.9190	0.9814	0.8143	0.9615	0.9444
Dense + Graph	0.5124	0.6807	0.8153	0.3761	0.6046	0.8706
R-GCN Graph Retriever	0.7324	0.9413	0.9780	0.8879	0.9579	0.9540
Dense-FT R-GCN Graph Retriever	0.7890	0.9729	0.9918	0.9477	0.9843	0.9781
Structure-Aware R-GCN Retriever	0.7863	0.9729	0.9926	0.9482	0.9854	0.9709

主指标中，Dense-FT R-GCN Graph Retriever 与 Structure-Aware R-GCN Retriever 位于同一水平段。后者的 Full Support@5 为 0.9482，前者为 0.9477；Full Support@10 分别为 0.9854 与 0.9843。两项完整支持指标的绝对差值均低于 0.002。

Recall@10 也呈现接近状态，Structure-Aware R-GCN Retriever 为 0.9926，Dense-FT R-GCN Graph Retriever 为 0.9918。相对而言，MRR 从 0.9781 变为 0.9709，说明更完整的 top10 覆盖并未同步转化为更靠前的首个正确证据排序。


2. 结构恢复指标

Connected Evidence Recall@10




Same metric compared across methods

Path Recall@10



Same metric compared across methods

Edge Recall@10



Same metric compared across methods

方法	Connected Evidence Recall@10	Path Recall@10	Edge Recall@10
BM25 + Graph	0.3303	0.3841	0.3820
Dense + Graph	0.4487	0.5813	0.5722
R-GCN Graph Retriever	0.7041	0.9039	0.8639
Dense-FT R-GCN Graph Retriever	0.7318	0.9433	0.8916
Structure-Aware R-GCN Retriever	0.8292	0.9712	0.9618

结构指标的变化更集中。与 Dense-FT R-GCN Graph Retriever 相比，Structure-Aware R-GCN Retriever 的 Connected Evidence Recall@10 从 0.7318 到 0.8292 ，绝对提升 0.0974 ； Path Recall@10 从 0.9433 到 0.9712 ，绝对提升 0.0278 ； Edge Recall@10 从 0.8916 到 0.9618 ，绝对提升 0.0702 。

这组结果表明，新一轮结构关系组织策略更容易覆盖 gold dependency path 与 gold dependency edge。相比之下，完整支持句是否同时进入 top5/top10 的指标已经接近饱和，因此新增结构覆盖没有在 Full Support 上表现为同等幅度的增长。

3. 检索输出形态

方法	检索耗时 / Query	平均返回节点数	平均返回边数
Dense-FT	21.43 ms	10.00	0.00
Dense-FT R-GCN Graph Retriever	33.69 ms	10.00	29.15
Structure-Aware R-GCN Retriever	38.23 ms	10.00	40.03

Structure-Aware R-GCN Retriever 平均返回边数为 40.03，高于 Dense-FT R-GCN Graph Retriever 的 29.15。这与结构指标的提升方向一致：返回结果中包含了更多可用于连接支持证据的关系信息。

与此同时，检索耗时从 33.69 ms/query 增至 38.23 ms/query。在当前结果中，结构恢复的提升比完整支持指标的变化更明显，而额外结构输出也带来了可观察的推理成本。

4. 阶段性观察

在本轮结果中，文本微调后的图检索基线已经把 Full Support@10 推到 0.9843。新结构策略进一步达到 0.9854，但增幅很小；Full Support@5 同样只从 0.9477 到 0.9482。

更清晰的差异出现在路径和边层面。Path Recall@10 达到 0.9712，Edge Recall@10 达到 0.9618，均高于已有图检索基线。也就是说，本阶段的主要变化更像是结构覆盖质量的改善，而不是完整支持句指标上的明显跃迁。