

Dense-FT 与 Memory Stream 阶段性效果报告

1. 核心结论

这轮结果显示，Dense-FT 相比普通 dense 检索有明显提升；Memory Stream 的主要指标基本贴近普通 dense 检索。

在同一测试集上，Dense-FT 把 Full Support@10 提到 0.8684，MRR 提到 0.8935，都明显高于 dense 基线。Memory Stream 的 Full Support@10=0.7600，几乎和 dense 的 0.7610 持平，MRR=0.8533 也只是微弱变化。

从结果上看，Dense-FT 的完整证据找回和排序指标都高于 dense 基线；Memory Stream 的指标变化很小。


2. 数据与实验规模

Dense-FT 训练用的是 HotpotQA 训练集上的大规模 pair 数据，合计 90,025 个训练任务、1,286,226 个训练 pair，其中正例 214,644 个。负例主要来自随机负例、BM25 hard negative 和图邻居 hard negative。

Memory Stream 这边用的是 1,000 个 task 的 importance 标注结果，一共覆盖 41,185 个 memory item，平均每个 task 大约 41.2 个 item。这个规模不小，不是少量样本试出来的趋势。

importance 标注的过程是：先尝试使用离线 7B 级别大模型做批量标注，但输出 JSON 不稳定，甚至出现结构无法闭合的问题；之后改成由 Codex 调用子代理，用 GPT-5.4-mini 对每个 task 中的 memory item 打 1-10 分。最终得到 1,000 个 task、41,185 个 memory item 的 importance 分数。

3. 主结果




方法	Recall@10	Full Support@10	MRR
BM25	0.8273	0.6180	0.8465
Dense	0.8906	0.7610	0.8527
Dense-FT	0.9440	0.8684	0.8935
Memory Stream	0.8911	0.7600	0.8533
Ours: R-GCN Graph Retriever	0.9611	0.9119	0.9170

Dense-FT 相比 dense，Full Support@10 提升了 +0.1144 ， MRR 提升了 +0.0406 。 Ours: R-GCN Graph Retriever 的 Full Support@10=0.9119 ， 是这组主指标里最高的结果。

Memory Stream 基本贴着 dense 走， Full Support@10 差值为 -0.0010 。

4. 连通性表现



方法	Connected Evidence Recall@10	Query-Evidence Connectivity@10
BM25	0.4565	0.5948
Dense	0.5944	0.7473
Dense-FT	0.6919	0.8554
Memory Stream	0.6100	0.7550

连通性结果中，Dense-FT 的 Connected Evidence Recall@10 比 dense 高 +0.0975，Query-Evidence Connectivity@10 比 dense 高 +0.1082。Memory Stream 的两个连通性指标分别比 dense 高 +0.0156 和 +0.0077。

5. 为什么 Memory Stream 效果一般

Memory Stream 的核心是 relevance + importance + recency 的加权，但 HotpotQA 没有真实的 recency / 时间顺序信息，所以 recency 这一项在这里天然就没有发挥空间。

剩下真正能起作用的，其实主要就是 relevance 和 importance。问题在于，这次 importance 的 grid search 没有找到一個像样的“高 importance 更好”的区间，最优点最后落在 importance_weight = 0.01，已经非常接近把 importance 关掉了。

Memory Stream importance sweep: the curve is flat near zero and drops as importance grows

Selected point is 0.01; recency weight is effectively disabled because HotpotQA has no temporal signal



从扫参曲线看得很直观：

importance_weight	Full Support@10	MRR
0.00	0.761	0.8527
0.01	0.760	0.8533
0.05	0.762	0.8504
0.10	0.760	0.8423
0.20	0.750	0.8305
0.50	0.663	0.7677
1.00	0.485	0.6571

这条曲线显示：importance 权重从 0.10 继续增大后，Full Support@10 和 MRR 都持续下降；最佳配置落在 0.01 这个接近零权重的位置。在这组 HotpotQA 实验里，importance 没有表现出足以超过 dense 的独立增益。