

Dense / Dense-FT 及其 R-GCN 变体跨数据集对比报告

本报告在两个多跳证据检索数据集上，对比四个方法：Dense、Dense-FT，以及分别以二者作为种子检索器的 R-GCN 图检索变体 Dense-RGCN、Dense-FT-RGCN。

四个方法的关系是：Dense 与 Dense-FT 是纯文本稠密检索（后者在目标数据上做了检索微调）；Dense-RGCN 与 Dense-FT-RGCN 在对应种子检索分数之上，用 2 层 R-GCN 对 memory 句子节点重新打分并输出 top-k 证据节点。因此每一对（Dense / Dense-RGCN、Dense-FT / Dense-FT-RGCN）可以直接看出"在同一种子上加图重排"带来的增量。


1. 数据规模

数据集	测试问题数	平均候选记忆数	平均返回节点数
HotpotQA	6,869	41.34	9.99
2WikiMultiHopQA	12,076	31.92	10.00

两个数据集的候选规模接近，top-k 截断都取 10。2WikiMultiHopQA 具有显式的 gold dependency path / edge 标注，因此可以评估 Path Recall@10 与 Edge Recall@10；HotpotQA 的 supporting facts 没有显式路径标注，这两项记录为 N/A。

2. 主检索指标

2.1 HotpotQA




方法	Recall@2	Recall@5	Recall@10	Evidence F1@5	Evidence F1@10	Full Support@5	Full Support@10	MRR
Dense	0.5448	0.7698	0.8886	0.4883	0.3404	0.5320	0.7538	0.8530
Dense-FT	0.6143	0.8548	0.9436	0.5426	0.3622	0.6896	0.8675	0.8932
Dense-RGCN	0.6665	0.8871	0.9600	0.5656	0.3696	0.7599	0.9090	0.9156
Dense-FT-RGCN	0.6961	0.9088	0.9687	0.5800	0.3733	0.7998	0.9279	0.9305

四个方法在 HotpotQA 上呈现清晰的单调递增：Dense < Dense-FT < Dense-RGCN < Dense-FT-RGCN，Dense-FT-RGCN 在全部主指标上最高。

- 在同种子上加 R-GCN 的增量：Dense-RGCN 相对 Dense 的 Full Support@10 从 0.7538 升到 0.9090（+0.1552，相对 +20.6%），Full Support@5 从 0.5320 升到 0.7599（+0.2279，相对 +42.8%）。Dense-FT-RGCN 相对 Dense-FT 的 Full Support@5 从 0.6896 升到 0.7998（+0.1102，相对 +16.0%），Full Support@10 从 0.8675 升到 0.9279（+0.0604，相对 +7.0%）。
- 微调种子的增量：在都接 R-GCN 的前提下，Dense-FT-RGCN 相对 Dense-RGCN 的 Recall@5 高 0.0217，Full Support@10 高 0.0189，MRR 高 0.0149。说明 Dense-FT 种子带来的更好初始排序，会进一步被 R-GCN 放大。

2.2 2WikiMultiHopQA



方法	Recall@2	Recall@5	Recall@10	Evidence F1@5	Evidence F1@10	Full Support@5	Full Support@10	MRR
Dense	0.5383	0.6776	0.7953	0.4229	0.2994	0.3628	0.5586	0.8633
Dense-FT	0.7019	0.9190	0.9814	0.5881	0.3792	0.8143	0.9615	0.9444
Dense-RGCN	0.7277	0.9351	0.9742	0.6036	0.3770	0.8764	0.9506	0.9525
Dense-FT-RGCN	0.7867	0.9706	0.9906	0.6242	0.3825	0.9444	0.9824	0.9746


2WikiMultiHopQA 上 Dense-FT-RGCN 同样在几乎所有主指标上最高，但出现一个值得注意的细节：

- Dense-RGCN 相对 Dense-FT 在靠前位置更强（Recall@2 0.7019→0.7277，Full Support@5 0.8143→0.8764，+0.0621），但在 Recall@10 和 Full Support@10 上略低（0.9814→0.9742、0.9615→0.9506）。也就是说，仅用 Dense 种子的 R-GCN 把更多证据顶到前排，但在已经很宽松的 top10 上没有超过经过微调的 Dense-FT。
- Dense-FT-RGCN 没有这个折衷：它在 Full Support@5（0.9444）、Full Support@10（0.9824）、Recall@10（0.9906）上都最高，相对 Dense-FT 的 Full Support@5 提升 +0.1301（相对 +16.0%），Recall@2 提升 +0.0848（相对 +12.1%）。

综合两个数据集，R-GCN 的增益最集中在靠前位置和完整证据找回（Recall@2、Full Support@5）；而 Dense-FT-RGCN（微调种子 + 图重排）是唯一在两个数据集上都不出现指标回退的方法。

3. 结构指标

3.1 HotpotQA




方法	Connected Evidence Recall@5	Connected Evidence Recall@10	Query-Evidence Connectivity@10	Path Recall@10	Edge Recall@10
Dense	0.3773	0.5944	0.7471	N/A	N/A
Dense-FT	0.4969	0.6914	0.8546	N/A	N/A
Dense-RGCN	0.5711	0.7343	0.8958	N/A	N/A
Dense-FT-RGCN	0.5982	0.7524	0.9135	N/A	N/A


结构连通性上四个方法依旧单调递增。Dense-FT-RGCN 的 Query-Evidence Connectivity@10 达到 0.9135，相对 Dense 的 0.7471 高 0.1664，相对 Dense-FT 的 0.8546 高 0.0589。这说明图重排不仅找回更多证据，也更倾向于选出在图上彼此连通、能共同构成证据链的节点。HotpotQA 无 gold path / edge 标注，Path Recall@10 与 Edge Recall@10 为 N/A。

3.2 2WikiMultiHopQA

2WikiMultiHopQA — Structural Connectivity



2WikiMultiHopQA — Path / Edge Recovery (RGCN only)



方法	Connected Evidence Recall@5	Connected Evidence Recall@10	Query-Evidence Connectivity@10	Path Recall@10	Edge Recall@10
Dense	0.2010	0.3968	0.5535	N/A	N/A
Dense-FT	0.5554	0.7246	0.9432	N/A	N/A


方法	Connected Evidence Recall@5	Connected Evidence Recall@10	Query-Evidence Connectivity@10	Path Recall@10	Edge Recall@10
Dense-RGCN	0.5754	0.6944	0.9325	0.8943	0.8561
Dense-FT-RGCN	0.6341	0.7304	0.9627	0.9399	0.8892

2WikiMultiHopQA 提供 gold path / edge 标注，因此只有 R-GCN 变体能给出 Path Recall@10 与 Edge Recall@10 。Dense-FT-RGCN 的 Path Recall@10=0.9399 、 Edge Recall@10=0.8892 ，均高于 Dense-RGCN 的 0.8943 / 0.8561 ，说明微调种子也让图模型恢复出更准确的依赖路径与边。

需要注意 Connected Evidence Recall@10 上，Dense-RGCN （0.6944 ）略低于 Dense-FT （0.7246 ），与 2.2 节 Full Support@10 的折衷一致；Dense-FT-RGCN （0.7304 ）则重新回到最高，说明这一回退由 Dense 种子的上限造成，换成 Dense-FT 种子后被补回。

4. 效率指标


4.1 HotpotQA



方法	检索耗时 / Query	平均候选记忆数	平均返回边数
Dense	27.41 ms	41.34	0.00
Dense-FT	28.93 ms	41.34	0.00
Dense-RGCN	53.02 ms	41.34	28.76

方法	检索耗时 / Query	平均候选记忆数	平均返回边数
Dense-FT-RGCN	55.30 ms	41.34	28.84

4.2 2WikiMultiHopQA



方法	检索耗时 / Query	平均候选记忆数	平均返回边数
Dense	22.18 ms	31.92	0.00
Dense-FT	21.84 ms	31.92	0.00
Dense-RGCN	34.73 ms	31.92	28.60
Dense-FT-RGCN	37.70 ms	31.92	30.30

R-GCN 的质量提升伴随推理成本上升。HotpotQA 上 Dense-FT-RGCN 的 55.30 ms/query 约为 Dense-FT 28.93 ms 的 1.9 倍；2WikiMultiHopQA 上 37.70 ms 约为 Dense-FT 21.84 ms 的 1.7 倍。额外开销主要来自图上的 message passing 与节点 scorer。Dense 与 Dense-FT 不输出边（返回边数为 0），R-GCN 变体平均返回约 29-30 条边，提供了文本检索方法没有的结构化证据。

5. 小结

- 两个数据集上，加 R-GCN 图重排都能在同一种子之上带来明显增益，增益最集中在 Recall@2、Full Support@5 和结构连通性指标。
- Dense-FT-RGCN（微调种子 + 图重排）是唯一在 HotpotQA 与 2WikiMultiHopQA 上都没有出现指标回退的方法，且在两数据集的绝大多数主指标和全部结构指标上最高。
- 仅用 Dense 种子的 Dense-RGCN 在 2WikiMultiHopQA 的宽松 top10 指标上略低于 Dense-FT，说明种子质量决定了图重排能达到的上限；微调种子后这一回退被补回。

- 质量提升的代价是检索延迟提高到种子方法的约 1.7-1.9 倍，但 R-GCN 变体额外提供平均约 29-30 条结构化证据边，这是纯文本检索不具备的能力。