

LongMemEval V1 检索实验报告


1. 数据规模与评估表面

数据切分	问题数	平均候选记忆数	平均图边数
Train	300	495.42	2828.50
Dev	100	493.30	2817.44
Test	40	489.60	2793.20

本次评估中，每个问题平均需要在约 490 条候选记忆中检索目标证据。图构建后，每个问题平均包含约 2800 条边，且没有孤立记忆节点。测试集边类型以实体重合边为主，占全部边约 81.7%；顺序边约 15.8%；桥接边和查询重合边合计约 2.5%。

从评价表面看，LongMemEval V1 当前主要提供 Turn 与 Session 两个粒度的召回、完整支持和排序位置指标。实验计划中强调的依赖路径与边恢复指标，在本批结果中均记录为 N/A。因此，这份表更集中地呈现“目标记忆轮次/会话是否被排入前列”，而不是直接呈现“连接证据链是否被恢复”。

2. 主检索指标




方法	Turn Recall@5	Turn Recall@10	Full Turn Support@10	Session Recall@5	Session Recall@10	Full Session Support@10	MRR
BM25	0.6517	0.7733	0.6750	0.8313	0.9000	0.8500	0.5465
BM25 + Graph	0.6350	0.7825	0.7250	0.7938	0.8750	0.8250	0.5345
Dense	0.8050	0.9342	0.8500	0.9104	0.9854	0.9500	0.6367
Dense + Graph	0.7858	0.9383	0.8500	0.9167	0.9854	0.9500	0.6475
Memory Stream	0.8050	0.9342	0.8500	0.9104	0.9854	0.9500	0.6492
Dense-FT	0.9442	1.0000	1.0000	0.9917	1.0000	1.0000	0.8563
Graph Retriever (Dense)	0.8433	0.9275	0.8750	0.9688	0.9750	0.9750	0.7749
Graph Retriever (Dense-FT)	0.8842	0.9650	0.9250	0.9500	1.0000	1.0000	0.8002

Dense-FT 是本次表中最强的主检索结果。相比 Dense，Dense-FT 的 Turn Recall@10 从 0.9342 提高到 1.0000，Full Turn Support@10 从 0.8500 提高到 1.0000，MRR 从 0.6367 提高到 0.8563。在 40 个测试问题上，Dense-FT 的完整 Turn 支持失败数为 0。

Memory Stream 与 Dense 的六个 Recall / Full Support 指标完全一致：Turn Recall@5、Turn Recall@10、Full Turn Support@10、Session Recall@5、Session Recall@10、Full Session Support@10 均相同。两者的完整 Turn 支持失败问题也完全一致，均为 6 个。Memory Stream 只在 MRR 上从 0.6367 到 0.6492，绝对增加 0.0125。

Dense vs Memory Stream



这一组对照说明，Memory Stream 的附加排序项在本批测试中没有改变 top10 命中集合，也没有改变完整支持失败集合；它主要表现为首个命中位置上的轻微变化。

3. 反常现象解释

Memory Stream 的结果接近 Dense，主要来自它的打分形式和调参结果。该方法的最终分数由语义相关性、recency 和 importance 加权组成；本次开发集调参选出的权重为

`relevance_weight=1.0`、`recency_weight=0.01`、`importance_weight=0.0`。也就是说，最终排序几乎完全由 Dense 相关性分数决定，recency 只保留为很小的排序扰动项。若 recency 能稳定补充语义相关性，它通常会在调参中获得更高权重；当前权重选择说明时间先验在这批任务上没有形成稳定正信号，加入后更容易改变局部顺序，而不是改变 top10 命中集合。

Graph Retriever (Dense-FT) 低于 Dense-FT，也需要结合指标上限来看。Dense-FT 在测试集的 `Turn Recall@10` 和 `Full Turn Support@10` 已经达到 `1.0000`，因此图模型只有在完全不移动正确 Turn 的前提下，才可能继续保持或提高主指标。Graph Retriever (Dense-FT) 的 Session 级 top10 指标仍为 `1.0000`，说明它仍能覆盖目标会话；回落主要发生在更细的 Turn 粒度，表现为图重打分把部分同会话或近邻记忆排到了正确 Turn 之前。这类现象更像是粒度错位：图结构帮助维持会话覆盖，但没有在该数据的 Turn 级目标上带来更稳定的排序约束。

4. 图相关方法观察

BM25 + Graph 相比 BM25 的 `Full Turn Support@10` 从 `0.6750` 提高到 `0.7250`，但 `Turn Recall@5`、Session 级指标和 `MRR` 同时下降。这个变化说明图重排对稀疏词面检索有局部补充，但补充结果并不均匀地传导到所有指标。

Dense + Graph 相比 Dense 的 `Turn Recall@10` 从 `0.9342` 到 `0.9383`，`MRR` 从 `0.6367` 到 `0.6475`；`Full Turn Support@10`、`Session Recall@10` 和 `Full Session Support@10` 保持不变。也就是说，在 Dense 已经覆盖较多目标记忆的情况下，图重排主要改变了少量排序位置。

Graph Retriever (Dense) 相比 Dense 的 Turn Recall@5 从 0.8050 提高到 0.8433，Full Turn Support@10 从 0.8500 提高到 0.8750，MRR 从 0.6367 提高到 0.7749。同时，它的 Turn Recall@10 从 0.9342 到 0.9275，Session Recall@10 从 0.9854 到 0.9750。这组结果更偏向提升靠前位置和会话覆盖质量，而不是在所有 top10 指标上同步提高。

Graph Retriever (Dense-FT) 的训练已完成，测试结果也明显高于未微调的 Dense 系列；但与 Dense-FT 本身相比，它的 Turn Recall@5 从 0.9442 到 0.8842，Turn Recall@10 从 1.0000 到 0.9650，Full Turn Support@10 从 1.0000 到 0.9250，MRR 从 0.8563 到 0.8002。Session 级 top10 指标仍保持 1.0000，说明该方法能够覆盖目标会话，但在更细的 Turn 粒度上没有延续 Dense-FT 的饱和结果。

5. 与已有证据追踪结果的参照

实验计划的核心评价目标是完整证据集合和连接关系恢复。把 LongMemEval V1 与已完成的 HotpotQA、2WikiMultiHopQA 结果放在一起看，三者呈现出的指标形态不同。

数据	平均候选记忆数	可展示的结构指标	图方法相对 Dense-FT 的形态
HotpotQA	41.34	结构连通性指标	Dense-FT-RGCN 的 Full Support@10 比 Dense-FT 高 0.0604，Query-Evidence Connectivity@10 高 0.0589
2WikiMultiHopQA	32.92	结构连通性、Path Recall、Edge Recall	Dense-FT-RGCN 的 Full Support@5 比 Dense-FT 高 0.1301，并给出 Path Recall@10=0.9399、Edge Recall@10=0.8892
LongMemEval V1	489.60	结构路径与边恢复列为 N/A	Dense-FT 的 top10 Turn / Session 完整支持达到 1.0000，Graph Retriever (Dense-FT) 在 Turn 粒度上低于 Dense-FT

这个参照使 LongMemEval V1 的结果边界比较清楚：它提供了更大的长期记忆候选池，也能记录 Turn 与 Session 粒度的命中情况；但在当前表格中，结构恢复相关列没有形成可比较数值。与 HotpotQA、2WikiMultiHopQA 相比，它更像一个长期对话检索压力测试，而不是直接展示证据链恢复收益的主表。

6. 小结

第一，本次 LongMemEval V1 表中最稳定的主结果来自 Dense-FT。它把 Turn 与 Session 粒度的 top10 完整支持都推到 1.0000，并且没有留下完整 Turn 支持失败案例。

第二，Memory Stream 与 Dense 在 Recall 和 Full Support 指标上完全重合，失败集合也一致；表中唯一差异是 MRR 的 0.0125 绝对变化。这个结果更适合作为排序细节观察，而不宜单独扩展成主效应。

第三，图相关方法在局部指标上有变化：BM25 + Graph 提高了稀疏检索的 Full Turn Support，Graph Retriever (Dense) 提高了 MRR 和部分靠前指标。但在 Dense-FT 已达到 top10 饱和的设置下，Graph Retriever (Dense-FT) 没有继续提高 Turn 级主指标。

第四，与 HotpotQA 和 2WikiMultiHopQA 的证据追踪表相比，LongMemEval V1 当前更突出“长期候选池中的目标轮次检索”，而结构连通、依赖路径和边恢复的展示空间较小。后续论文主结果可以继续把结构恢复分析放在具备对应标注和可

计算指标的数据上，LongMemEval V1 则作为长期记忆检索场景的补充记录。