

MuSiQue 多跳证据检索基线对比报告

本报告在 MuSiQue 多跳问答数据集上，系统评估七个检索方法的证据检索能力。MuSiQue 的问题需要跨多个支持段落组合作答（含 2 至 4 跳的组合式推理），对检索器的多跳证据聚合能力提出了比一般双跳数据集更高的要求。

七个方法可以归为三组，方便横向对照：

- **稀疏与稠密文本基线：** BM25 （词频稀疏检索）、Dense （通用稠密检索）、Dense-FT （在目标域上做过检索微调的稠密检索）。这三者只用文本相似度排序，不利用图结构。
- **轻量图重排：** BM25 + Graph 、 Dense + Graph 。它们在对应文本种子分数之上，用一个启发式的图邻域重排来调整候选顺序。
- **R-GCN 图检索：** Dense-RGCN 、 Dense-FT-RGCN 。它们分别以 Dense 、 Dense-FT 作为种子检索器，再用一个 2 层关系图卷积网络对记忆节点重新打分，输出 top-k 证据节点，并额外给出证据之间的结构化边。

这样的分组让每一组内可以直接比较"同一种子上换用不同图机制"的收益，也能比较"图机制固定、只换种子质量"的差异。


1. 数据规模

数据切分	问题数	平均候选记忆数	平均图边数	孤立记忆节点数
训练集	19,938	19.99	115.78	3,172
验证集	500	19.98	115.19	74
测试集	1,917	19.99	116.17	267

测试集共 1,917 道问题，每题平均约 20 条候选记忆句、约 116 条图边，top-k 截断统一取 10。相比常见的双跳数据集，MuSiQue 的候选池更小但推理链更长，因此 top10 指标并不像双跳数据集那样宽松，方法之间的差距更能反映真实的多跳聚合能力。

监督训练侧共约 46,613 个正例证据对，平均每题约 2.34 条 gold 支持句。图中边由桥接关系、实体重叠、查询重叠与顺序相邻四类构成，其中桥接边与实体重叠边占主体，为图模型提供了跨段落的连接线索。

2. 主检索指标




方法	Recall@2	Recall@5	Recall@10	Full Support@5	Full Support@10	MRR
BM25	0.3794	0.5520	0.7018	0.1883	0.3792	0.7544
BM25 + Graph	0.3961	0.6048	0.7709	0.2932	0.5295	0.7593
Dense	0.4750	0.6866	0.8507	0.3709	0.6421	0.8578
Dense + Graph	0.4835	0.7118	0.8720	0.4434	0.6954	0.8429
Dense-FT	0.5514	0.8079	0.9375	0.5842	0.8336	0.9148
Dense-RGCN	0.5487	0.8023	0.9363	0.5691	0.8346	0.8823
Dense-FT-RGCN	0.5913	0.8389	0.9460	0.6275	0.8545	0.9221

Dense-FT-RGCN 在全部六项主指标上均为最高，是唯一在每个维度都领先的方法。围绕它可以看出三条清晰的规律：

- **图机制对文本种子有稳定增益，且增益集中在完整证据找回上。** 稀疏种子上，BM25 + Graph 相对 BM25 的 Full Support@10 从 0.3792 升到 0.5295（相对 +39.6%），Full Support@5 从 0.1883 升到 0.2932（相对 +55.7%）。稠密种子上，Dense + Graph 相对 Dense 的 Full Support@5 从 0.3709 升到 0.4434（相对 +19.5%）。这说明图结构最擅长把"共同构成完整证据链"的句子一起顶上来，而这正是多跳问答最看重的能力。
- **R-GCN 图检索的增益远大于轻量图重排。** 同样基于 Dense 种子，学习式的 Dense-RGCN 相对 Dense 的 Full Support@5 从 0.3709 升到 0.5691（相对 +53.4%）、Full Support@10 从 0.6421 升到 0.8346（相对 +30.0%），增幅明显高于启发式 Dense + Graph 的对应提升。这表明在这种多跳、较密的图上，可学习的关系图卷积比固定规则的邻域重排更能挖出证据结构。
- **图重排可以补齐"不做微调"的差距。** 值得注意的是，仅用未微调稠密种子的 Dense-RGCN，在 Recall@10（0.9363 vs 0.9375）与 Full Support@10（0.8346 vs 0.8336）上已经和经过目标域微调的 Dense-FT 基本持平，只在 MRR 上仍落后（0.8823 vs 0.9148）。也就是说，图重排能在很大程度上替代文本微调带来的召回收益，但在把最相关证据排到最前（MRR）这件事上，微调种子仍有独立价值。
- **两者叠加最优。** Dense-FT-RGCN（微调种子 + 图检索）同时拿到两方面收益：相对 Dense-FT，Recall@2 提升 +0.0399（相对 +7.2%）、Full Support@5 提升 +0.0433（相对 +7.4%），且 MRR 回到 0.9221。


证据 F1



方法	Evidence F1@5	Evidence F1@10
BM25	0.3693	0.2873
BM25 + Graph	0.4037	0.3149
Dense	0.4555	0.3458
Dense + Graph	0.4706	0.3545
Dense-FT	0.5414	0.3844
Dense-RGCN	0.5369	0.3833
Dense-FT-RGCN	0.5627	0.3878

Evidence F1 同时约束精确率与召回率。所有方法的 F1@10 都低于 F1@5，这是因为把返回数放宽到 10 会引入更多非证据句，拉低精确率——在平均只有约 2.34 条 gold 支持句的 MuSiQue 上尤为明显。Dense-FT-RGCN 在两个位置都最高，说明它在扩大召回的同时对精确率的损耗控制得最好。


3. 结构指标



方法	Connected Evidence Recall@5	Connected Evidence Recall@10	Query-Evidence Connectivity@10
BM25	0.1763	0.3631	0.3792
BM25 + Graph	0.2827	0.5102	0.5295
Dense	0.3474	0.6109	0.6395
Dense + Graph	0.4288	0.6740	0.6948
Dense-FT	0.5430	0.7877	0.8284
Dense- RGCN	0.5274	0.7934	0.8273
Dense-FT- RGCN	0.5759	0.8075	0.8477

结构连通性衡量返回证据在图上是否彼此连通、是否能与问题构成完整推理链。Dense-FT-RGCN 三项全部最高，Query-Evidence Connectivity@10 达到 0.8477，相对 BM25 的 0.3792 高出一倍以上，相对 Dense-FT 的 0.8284 也有稳定领先。这说明图检索不只是找回更多正确句子，还更倾向于选出在图上相互连通、能共同支撑答案的节点组合。


路径与边恢复



方法	Path Recall@10	Edge Recall@10
BM25	N/A	N/A
BM25 + Graph	0.5102	0.5341
Dense	N/A	N/A
Dense + Graph	0.6740	0.6880
Dense-FT	N/A	N/A
Dense-RGCN	0.7934	0.7818
Dense-FT-RGCN	0.8075	0.7896

Path Recall@10 与 Edge Recall@10 衡量方法对 gold 依赖路径与依赖边的恢复能力，只有会输出结构化边的图方法才能给出这两项，纯文本基线（BM25、Dense、Dense-FT）记为 N/A。在能对比的四个图方法里，R-GCN 图检索显著优于轻量图重排：Dense-RGCN 的 Path Recall@10=0.7934 明显高于 Dense + Graph 的 0.6740；Dense-FT-RGCN 进一步升至 0.8075（Edge Recall@10=0.7896），是路径与边恢复上最强的方法。这一维度是纯文本检索完全不具备的能力，也是图方法在多跳场景下最有辨识度的优势。


4. 效率指标



方法	平均返回节点数	平均返回边数
BM25	10.00	0.00
BM25 + Graph	10.00	34.11
Dense	10.00	0.00
Dense + Graph	10.00	38.57
Dense-FT	10.00	0.00
Dense-RGCN	10.00	29.30
Dense-FT-RGCN	10.00	31.68

所有方法都稳定返回 10 个证据节点。差异在于结构化输出：三个纯文本基线不产生边，而图方法平均额外返回约 29–39 条证据边。这些边把离散的证据句连成可追溯的推理链，为下游的答案生成与可解释性提供了文本检索没有的结构信息。R-GCN 图检索返回的边数（约 29–32 条）略少于轻量图重排（约 34–39 条），但从第 3 节的路径/边恢复看，它返回的边更贴合 gold 依赖结构，是"更少但更准"的结构输出。

Retrieval Latency per Query (ms)



方法	检索耗时 / Query
BM25	0.91 ms
BM25 + Graph	0.23 ms
Dense	44.27 ms
Dense + Graph	0.44 ms
Dense-FT	105.44 ms
Dense-RGCN	50.09 ms
Dense-FT-RGCN	50.44 ms

需要说明这里的耗时口径：图方法（含轻量图重排与 R-GCN 图检索）统计的是检索评估阶段的耗时，不包含图结构的构建时间，而图构建是可以离线预处理、在多次查询间摊薄的一次性开销。因此表中图方法的绝对耗时会明显偏低，不能与纯文本基线直接横向相减比较（例如 Dense + Graph 的评估耗时低于其种子 Dense，正是因为前者不计入建图时间）。可以稳妥得到的结论是：稀疏检索的量级远低于稠密检索；R-GCN 图检索在检索阶段引入了额外的消息传递与节点打分开销，处在数十毫秒量级。要得到端到端的公平延迟对比，需要把图构建时间一并计入并在统一条件下重测，这里的数值仅反映检索评估阶段的量级，不作为方法优劣的判据。

5. 小结

- 在 MuSiQue 这一更长推理链的数据集上，Dense-FT-RGCN（微调种子 + R-GCN 图检索）在全部主检索指标与全部结构指标上均为最优，是综合能力最强的方法。

- 图机制对任何文本种子都能带来稳定增益，且增益最集中在完整证据找回（Full Support）与结构连通性上——这正是多跳问答的核心诉求。
- 可学习的 R-GCN 图检索明显强于启发式轻量图重排：无论是完整证据找回还是路径/边恢复，前者的提升幅度都更大。
- 图重排能在召回类指标上很大程度替代文本微调的收益（未微调的 Dense-RGCN 在 Recall@10、Full Support@10 上已追平 Dense-FT），但要把最相关证据排到最前（MRR），微调种子仍有独立价值；两者叠加得到最优结果。
- 图方法独有的价值在于结构化输出：平均额外返回约 29–39 条证据边，并能恢复 gold 依赖路径与边，这是纯文本检索完全不具备的能力，代价是数十毫秒量级的额外检索开销。