

Phase 2 R-GCN 阶段进展与效果报告

1. 当前进展定位

当前结果对应 Phase 2 中的“可训练图检索器”子任务：已经完成 `dense_rgcn_graph_retriever` 的训练、测试和结果汇总，并与 `bm25`、`dense`、`bm25_graph_rerank`、`dense_graph_rerank` 做了同一 test split 上的对比。

对照 Phase 2 要求，目前我还没有完成整个 Phase 2。原始要求包括 Dense-FT、Memory Stream、GraphRAG、edge ablations，以及 main/path/ablation/efficiency 表。当前完成的是其中“Ours: Trainable Graph Retriever”这一条主线；Dense-FT、Memory Stream、GraphRAG baseline 和系统性 edge ablation 还没有全部补齐。因此本报告应理解为 Phase 2 的阶段性进展报告，而不是完整 Phase 2 终稿。

本阶段最重要的结论是：可训练 R-GCN 已经不只是跑通链路，而是在 evidence retrieval 的主要指标上明显超过非训练图重排版本。尤其是完整证据找回和结构连通性指标提升明显，说明训练后的图节点打分器确实学到了比固定 graph rerank 权重更有效的排序信号。

2. 当前实现方法


当前方法是一个 dense-seeded R-GCN evidence node scorer。它不直接生成答案，而是针对每个 query 和 memory graph，对 memory sentence node 打分并输出 top-k evidence nodes。

整体结构如下：

1. 文本编码：query 和 memory sentence 使用 `intfloat/e5-base-v2` 风格的 dense embedding。当前 embedding encoder 是 frozen 的，没有做端到端 fine-tuning。
2. 节点初始特征：每个节点输入包含文本 embedding，并拼接 seed retrieval 相关数值特征，例如 dense seed score、seed rank percentile，以及 question-node indicator。
3. 输入投影：`encoder_dim + node_feature_dim` 先经过一层 `Linear -> ReLU -> Dropout`，投影到 hidden state。
4. 图编码：使用 2 层 R-GCN，hidden dim 为 256。边类型包括 `bridge`、`entity_overlap`、`query_overlap`、`sequential`，并按方向展开为 relation id。当前 typed relation transform 为每类 relation 使用独立线性变换。
5. 节点打分：scorer MLP 输入为 `[h_node, h_query, h_node * h_query, sample_node_features]`，结构为 `Linear -> ReLU -> Dropout -> Linear`，也就是一层 hidden MLP，输出每个候选节点的 evidence logit。
6. 训练目标：使用 gold evidence node 作为正例，随机负例、BM25 hard negative、dense hard negative 和 graph-neighbor hard negative 作为负例，先用 BCE loss 训练 evidence/non-evidence 分类。

这个设计的边界也比较清楚：当前训练的是图上的节点 scorer，不训练图构造规则本身；图边仍由规则生成，top-k 截断也不是直接训练目标。因此当前结果说明“在已有 evidence graph 上训练节点排序有效”，还不能说模型已经学会自动构图。

3. 主指标效果



方法	Recall@2	Recall@5	Recall@10	Evidence F1@5	Evidence F1@10	Full Support@5	Full Support@10	MRR
bm25	0.4738	0.6788	0.8127	0.4309	0.3101	0.3750	0.6004	0.8270
bm25_graph_rerank	0.4818	0.7194	0.8610	0.4569	0.3295	0.4490	0.7011	0.8222
dense	0.5448	0.7697	0.8887	0.4882	0.3404	0.5320	0.7540	0.8530
dense_graph_rerank	0.5386	0.7777	0.8946	0.4938	0.3430	0.5503	0.7703	0.8521
dense_rgcg_graph_retriever	0.6695	0.8888	0.9582	0.5665	0.3688	0.7618	0.9070	0.9195


R-GCN 在表中所有主指标上都是最高。相对最强非训练图方法 dense_graph_rerank ，提升主要体现在以下几项：

指标	dense_graph_rerank	dense_rgcg_graph_retriever	绝对提升	相对提升
Recall@5	0.7777	0.8888	+0.1111	+14.3%
Full Support@5	0.5503	0.7618	+0.2115	+38.4%
Full Support@10	0.7703	0.9070	+0.1367	+17.7%
MRR	0.8521	0.9195	+0.0673	+7.9%

这里最值得强调的是 Full Support 。普通 Recall 只看 gold evidence 的平均召回比例，而 Full Support 要求一个样本的所有 supporting evidence 同时进入 top-k。R-GCN 的 Full Support@10=0.9070 ，说明大多数 test 样本已经能在 top-10 中完整找回 supporting evidence；相对 dense_graph_rerank 的 0.7703 ，提升比较明显。

MRR 也有提升，说明模型不只是补全后排证据，也让首个正确 evidence 更靠前。不过从任务目标看，更关键的仍是完整证据集合能否被找全，因为这个项目评估的是 evidence tracing，而不是单个相关句子的 first hit。

4. 结构连通性效果




方法	Connected Evidence Recall@5	Connected Evidence Recall@10	Query-Evidence Connectivity@10	Path Recall@10	Edge Recall@10
bm25	0.2632	0.4565	0.5948	N/A	N/A
bm25_graph_rerank	0.3520	0.5721	0.6988	N/A	N/A
dense	0.3773	0.5946	0.7473	N/A	N/A
dense_graph_rerank	0.4070	0.6219	0.7666	N/A	N/A
dense_rgcn_graph_retriever	0.5702	0.7318	0.8931	N/A	N/A

结构指标更能体现图方法的意义。相对 dense_graph_rerank，R-GCN 的 Connected Evidence Recall@5 从 0.4070 提升到 0.5702，Connected Evidence Recall@10 从 0.6219 提升到 0.7318，Query-Evidence Connectivity@10 从 0.7666 提升到 0.8931。

这说明训练后的模型不只是选择语义相似的句子，还更倾向于选择在图结构上能共同形成证据链的节点。对于多跳 evidence tracing，这比单纯提高 Recall 更重要。

Path Recall@10 和 Edge Recall@10 当前仍为 N/A，原因是 HotpotQA supporting facts 没有显式 gold dependency path / gold dependency edge 标注。当前实验能评估 evidence node 是否找全、找全后是否连通，但还不能严格评估 gold path recovery。


5. 训练过程与稳定性



本次训练使用 90,025 个训练 task，构造出 1,715,125 个训练 pair，其中正例 214,644 个，负例 1,500,481 个，负正比例约 6.99:1。负例中包含随机负例、BM25 hard negative、dense hard negative 和 graph-neighbor hard negative，因此训练信号不只是区分明显无关句子，也覆盖了更容易混淆的候选证据。

训练共 20 个 epoch。train_loss 从 0.8733 降到 0.4975。最佳 dev composite 出现在 epoch 19，对应 dev Recall@5=0.8916、dev Full Support@5=0.7560、dev Full Support@10=0.9240、dev MRR=0.9269。epoch 20 的 MRR 继续上升，但 Recall 和 Full Support 回落，说明最终 checkpoint 选择不能只看 loss 或单个排序指标。

6. 效率代价



方法	Retrieval Latency / Query	Memory Size	Avg Retrieved Nodes	Avg Retrieved Edges
bm25	0.66 ms	41.34	9.99	0.00

方法	Retrieval Latency / Query	Memory Size	Avg Retrieved Nodes	Avg Retrieved Edges
bm25_graph_rerank	1.14 ms	41.34	9.99	34.24
dense	34.78 ms	41.34	9.99	0.00
dense_graph_rerank	36.10 ms	41.34	9.99	35.34
dense_rgc_n_graph_retriever	84.63 ms	41.34	9.99	28.45

R-GCN 的检索质量提升不是免费的。它的平均检索延迟为 84.63 ms/query，高于 dense 的 34.78 ms/query 和 dense_graph_rerank 的 36.10 ms/query。这部分代价主要来自图模型推理阶段的 message passing 和节点 scorer。

从当前阶段看，这个结果说明质量收益已经比较明确，但后续如果要做更完整的系统评估，还需要把质量提升和推理成本放在一起比较。

7. 尚未完成的 Phase 2 内容

按照原始项目要求，Phase 2 不是只做 R-GCN。当前还缺少以下部分：

要求	当前状态
Dense-FT baseline	尚未完成
Memory Stream baseline	尚未完成
GraphRAG baseline	尚未完成
Edge ablation	尚未系统完成
ablation_results.csv	尚未形成完整表
Path / edge gold label 评估	HotpotQA 当前标注口径下仍不可直接评估
完整论文式实验结构	目前只有阶段性主结果、连通性结果和效率结果